



Inteligencia Artificial
Ingeniería en Sistemas de Información
Año 2026

Trabajo Práctico Cuatrimestral

Primera entrega

GRUPO N° 02

Apellido y Nombres	Dirección de E-Mail
Montiron Francisco - 31091	franciscomontiron@gmail.com
Bogado Demian - 31173	
Cendoya Ramiro - 30602	
Martínez Lucas - 30697	
Díaz Valentina - 30628	
Bravo Federico - 30833	

Fecha de Presentación

02/05/2026

Universidad Tecnológica Nacional
Facultad Regional La Plata

Resumen

El presente trabajo aborda el desarrollo de un sistema de clasificación automática de lesiones cutáneas a partir de imágenes dermatoscópicas, utilizando una Red Neuronal Artificial (RNA) de tipo Perceptrón Multicapa (MLP) entrenada mediante el algoritmo de Backpropagation. El cáncer de piel constituye el tipo de cáncer más frecuente a nivel mundial, y su detección temprana es determinante para la supervivencia del paciente. Se utiliza el dataset HAM10000, compuesto por 10.015 imágenes procesadas a 8×8 píxeles en escala de grises, clasificadas en 7 categorías diagnósticas. La arquitectura propuesta consta de una capa de entrada de 64 neuronas, dos capas ocultas de 128 y 64 neuronas con activación ReLU, y una capa de salida de 7 neuronas con activación Softmax. La implementación se realizará en Python mediante la librería scikit-learn.

Palabras clave: redes neuronales artificiales, Backpropagation, clasificación de imágenes, cáncer de piel, Perceptrón Multicapa, HAM10000.

1. Introducción y Descripción del Problema

1.1. Contexto y Relevancia

El cáncer de piel es el tipo de cáncer más frecuente a nivel mundial. Según la Organización Mundial de la Salud (OMS), cada año se diagnostican aproximadamente 1,5 millones de nuevos casos de cáncer de piel no melanoma y más de 325.000 casos de melanoma. La detección temprana es el factor más determinante para la supervivencia del paciente: un melanoma diagnosticado en estadio I tiene una tasa de supervivencia a 5 años superior al 98%, que cae a menos del 25% en estadios avanzados.

El diagnóstico tradicional requiere la evaluación visual por parte de un dermatólogo especializado y, en muchos casos, una biopsia confirmatoria. Sin embargo, la escasez de especialistas en regiones con recursos limitados, sumada a la variabilidad entre observadores, constituye una brecha significativa en la atención médica.

1.2. Problema a Resolver

El problema consiste en clasificar automáticamente imágenes dermatoscópicas de lesiones cutáneas en 7 categorías diagnósticas, utilizando los píxeles de la imagen como entrada a una Red Neuronal Artificial con algoritmo de aprendizaje Backpropagation. Las categorías diagnósticas se detallan en la Tabla 1.

Tabla 1. Categorías diagnósticas del dataset HAM10000.

Etiqueta	Código	Nombre	Tipo
0	akiec	Queratosis actínica e intraepitelial	Potenc. maligna
1	bcc	Carcinoma basocelular	Maligna
2	bkl	Lesiones tipo queratosis benigna	Benigna
3	df	Dermatofibroma	Benigna
4	nv	Nevos melanocíticos (lunares)	Benigna
5	vasc	Lesiones vasculares	Benigna
6	mel	Melanoma	Maligna

1.3. Justificación del Uso de Redes Neuronales

Un software tradicional basado en reglas determinísticas (if-then, programación estructurada) no puede resolver este problema de manera eficaz, por las siguientes razones:

- No existen reglas explícitas que definan con precisión los límites visuales entre categorías; las diferencias son sutiles y se expresan en combinaciones complejas de color, textura y forma.
- La variabilidad intraclase es alta: dos melanomas pueden verse visualmente muy distintos entre sí.
- Se requiere aprendizaje estadístico a partir de miles de ejemplos, no de reglas codificadas manualmente.
- El problema pertenece al dominio del reconocimiento de patrones visuales, donde las RNA superan ampliamente a los algoritmos determinísticos clásicos.

2. Modelo de Red Neuronal Artificial

2.1. Modelo Seleccionado

Se selecciona un Perceptrón Multicapa (MLP) entrenado mediante el algoritmo de Backpropagation (retropropagación del error) como modelo de Red Neuronal Artificial para abordar el problema de clasificación.

2.2. Justificación del Modelo

La elección del MLP con Backpropagation se fundamenta en los siguientes criterios:

- Problema de clasificación multiclase no lineal: Las 7 clases de lesiones no son linealmente separables en el espacio de píxeles. El MLP con capas ocultas tiene la capacidad de aprender fronteras de decisión no lineales complejas mediante sus funciones de activación no lineales (ReLU).
- Capacidad de aproximación universal: El teorema de aproximación universal garantiza que un MLP con al menos una capa oculta suficientemente grande puede aproximar cualquier función continua, lo que lo hace apto para mapear patrones de píxeles a etiquetas de diagnóstico.
- Adecuación al tipo de entrada: Las imágenes están preprocesadas como vectores de 64 píxeles (8×8 píxeles en escala de grises), lo que produce un vector de entrada de dimensión fija, formato ideal para la capa de entrada de un MLP.
- Aprendizaje supervisado: El dataset cuenta con etiquetas diagnósticas confirmadas por histopatología, lo que permite el entrenamiento supervisado propio del algoritmo Backpropagation.
- Alternativa descartada (Hopfield): La red de Hopfield es adecuada para recuperación de patrones y memoria asociativa, pero no para clasificación multiclase con miles de ejemplos distintos, por lo que queda descartada.

2.3. Arquitectura Propuesta

La arquitectura de la red neuronal se compone de cuatro capas, cuya configuración se detalla en la Tabla 2.

Tabla 2. Arquitectura de la Red Neuronal Propuesta.

Capa	Neuronas	Función de Activación
Entrada	64	—
Oculto 1	128	ReLU
Oculto 2	64	ReLU
Salida	7	Softmax

Los hiperparámetros de entrenamiento seleccionados son los siguientes: función de pérdida: entropía cruzada categórica (Cross-Entropy Loss); optimizador: Adam (variante adaptativa de Gradient Descent); tasa de aprendizaje: 0,001 (ajustable durante experimentación); regularización: Dropout (a definir en la entrega final según resultados experimentales). La arquitectura puede ajustarse durante la experimentación; la configuración definitiva se reportará en la entrega final.

3. Patrones Utilizados

3.1. Fuente del Dataset

Se utiliza el dataset HAM10000 (Human Against Machine with 10000 training images), disponible en Kaggle y el ISIC Archive (International Skin Imaging Collaboration). La referencia principal es: Tschandl P., Rosendahl C., Kittler H. «The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions.» Scientific Data, 2018.

3.2. Descripción de los Datos

El dataset en su forma procesada para RNA (hmnist_8_8_L.csv) contiene 10.015 muestras, cada una representada por 64 características de entrada correspondientes a los píxeles de una imagen dermatoscópica de 8×8 en escala de grises. Los valores de píxel oscilan entre 0 y 255, y serán normalizados al rango [0, 1] mediante división por 255. La variable de salida es una etiqueta numérica de 0 a 6 que indica la clase diagnóstica.

3.3. Distribución de Clases

La distribución de muestras por clase diagnóstica se presenta en la Tabla 3. Se observa un marcado desbalance de clases, con predominancia de nevos melanocíticos (66,9% del total).

Tabla 3. Distribución de muestras por clase diagnóstica.

Etiqueta	Clase	Muestras	Porcentaje
0	akiec — Queratosis actínica	327	3,3%
1	bcc — Carcinoma basocelular	514	5,1%
2	bkl — Queratosis benigna	1.099	11,0%
3	df — Dermatofibroma	115	1,1%
4	nv — Nevo melanocítico	6.705	66,9%
5	vasc — Lesión vascular	142	1,4%
6	mel — Melanoma	1.113	11,1%
Total		10.015	100%

3.4. División Entrenamiento / Validación

Conforme a los requisitos de la cátedra (mínimo 25% para validación), el dataset se dividirá de la siguiente manera: 75% para entrenamiento (7.511 muestras) y 25% para validación (2.504 muestras). La división se realizará de forma estratificada para mantener la proporción de clases en ambos conjuntos.

3.5. Ejemplos de Patrones de Entrada

Cada patrón de entrada consiste en un vector de 64 valores enteros correspondientes a los píxeles de la imagen dermatoscópica redimensionada a 8×8 en escala de grises. El vector completo de cada muestra en el archivo CSV tiene la forma: pixel0000, pixel0001, ..., pixel0063, label. A continuación se presentan extractos representativos de los primeros valores de tres clases distintas:

- akiec (label=0): [85, 177, 193, 182, 179, 192, 121, 40, 25, 115, 152, 155, 153, 165, 148, 69, ...]
- bcc (label=1): [144, 236, 227, 217, 220, 233, 226, 177, 157, 234, 226, 220, 222, 234, 237, 197, ...]
- mel (label=6): [151, 165, 180, 184, 186, 185, 180, 163, 152, 171, 183, 188, 191, 189, 183, 164, ...]

4. Herramientas, Lenguaje y Librerías

4.1. Lenguaje de Programación

Se utiliza Python 3.x como lenguaje de desarrollo, dado que constituye el estándar de la industria para el desarrollo de sistemas de aprendizaje automático y redes neuronales artificiales. Python ofrece un ecosistema maduro de librerías especializadas, amplia documentación y facilidad de experimentación iterativa.

4.2. Librerías Principales

Las librerías utilizadas en el proyecto se detallan en la Tabla 4.

Tabla 4. Librerías y herramientas del proyecto.

Librería	Versión	Uso en el proyecto
scikit-learn	≥ 1.3	Implementación del MLP (MLPClassifier), división train/test, métricas
pandas	≥ 2.0	Carga y manipulación del dataset CSV
numpy	≥ 1.24	Operaciones matriciales, normalización de píxeles
matplotlib	≥ 3.7	Visualización de curvas de aprendizaje y matriz de confusión
seaborn	≥ 0.12	Visualización avanzada de resultados

4.3. Justificación de la Herramienta

Se selecciona MLPClassifier de scikit-learn por tratarse de una implementación robusta y ampliamente documentada del Perceptrón Multicapa con Backpropagation. Permite configurar el número de capas, cantidad de neuronas, función de activación, optimizador y tasa de aprendizaje, siendo ideal para experimentación académica. Como alternativa se consideró TensorFlow/Keras, que ofrece mayor flexibilidad para arquitecturas complejas; sin embargo, para el alcance de este trabajo scikit-learn resulta suficiente y reduce la complejidad del entorno de ejecución.

4.4. Entorno de Desarrollo

El entorno de desarrollo utilizado es Visual Studio Code y Jupyter Notebook. El código se desarrollará en formato Jupyter Notebook (.ipynb) para facilitar la documentación iterativa y la visualización inline de resultados durante la experimentación.

5. Referencias

- [1] Tschandl, P., Rosendahl, C., & Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161.
- [2] Organización Mundial de la Salud (OMS). Cáncer de piel — datos y cifras. Consultado en 2026.
- [3] Haykin, S. (2009). *Neural Networks and Learning Machines* (3.^a ed.). Pearson.
- [4] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [5] Hornik, K. (1991). Approximation capabilities of multilayer feedforward networks. *Neural Networks*, 4(2), 251–257.